Evolución de la Educación Superior en Bolivia: Un Estudio Temporal sobre el Crecimiento y la Desigualdad de Género en Matrículas y Titulaciones

Dávalos Alarcón Rodrigo
Mamani Cahuana Daniel Edgar
Flores Ulo Wilmer Alejandro
Salinas Condori Ian Ezequiel

5 de abril de 2026

1. Contextualización y Definición del Problema

1.1. Marco teórico y contextual

En el contexto global y particularmente en Bolivia, las universidades han asumido el reto de reducir la desigualdad, buscando democratizar el acceso al crecimiento profesional. Sin embargo, este incremento en la oferta educativa ha generado una paradoja: en lugar de equilibrar la balanza, ha consolidado la capacidad técnica de los centros donde se originaron estos modelos (como Europa), dejando rezagadas a otras regiones.

Bolivia, como nación latinoamericana, enfrenta esta brecha con un agravante estructural: el predominio del comercio informal sobre el empleo formal. Esta realidad subraya la importancia crítica de la educación superior; no solo se trata de masificar la matrícula, sino de garantizar que la formación académica permita al país competir en estándares internacionales a largo plazo.

El presente informe analiza los datos históricos de las universidades en Bolivia para diagnosticar el panorama educativo actual y evaluar si el camino trazado es el adecuado para los desafíos futuros. Si bien el mercado laboral presenta dificultades evidentes para los nuevos profesionales, este estudio no se centra en la empleabilidad, sino en el comportamiento de la accesibilidad a la educación visto desde perspectiva de las matrículas. Se parte de la premisa de que la educación superior mantiene su vigencia y utilidad, incluso en sectores tradicionalmente informales como los negocios. Por tanto, esta investigación se limita a un análisis descriptivo y prospectivo de los datos académicos disponibles.

1.2. Problematica

1.2.1. Problema principal

A pesar de los esfuerzos por masificar la educación superior en Bolivia, persiste una incertidumbre sobre la equidad y eficiencia del crecimiento de la matrícula. El problema central radica en la falta de un diagnóstico cuantitativo que determine si el aumento en el acceso a la universidad está reduciendo las brechas de género y desigualdades geográficas, o si simplemente está replicando modelos de concentración urbana y segregación por áreas de estudio que no se alinean con la realidad socioeconómica del país.

1.2.2. Problemas secundarios

- **Desconocimiento del ritmo de expansión**: No se tiene una medición precisa de la tasa de crecimiento anual de la matrícula, lo que impide determinar si el sistema universitario boliviano está en una fase de expansión sostenible o de estancamiento.

- **Segregación de género persistente**: Existe una brecha invisible en la elección de carreras y tasas de titulación entre hombres y mujeres, lo que sugiere que el acceso no es equitativo en todas las áreas del conocimiento (especialmente en sectores técnicos o de servicios).

- **Macrocefalia académica departamental**: La oferta y demanda educativa parecen estar altamente concentradas en el .ejeje troncal", dejando a los departamentos periféricos en una situación de desventaja competitiva y limitando la democratización del acceso profesional.

- **Desconexión entre formación y estructura económica**: Se observa una posible asimetría entre las áreas de estudio con mayor volumen de matriculados y las necesidades de un mercado laboral marcado por la informalidad, lo que podría generar una saturación en sectores de baja productividad.

- **Incertidumbre prospectiva**: La ausencia de proyecciones basadas en datos históricos dificulta la planificación estratégica de las instituciones educativas para anticipar la demanda futura de infraestructura y recursos docentes.

1.3. Objetivos

1.3.1. Objetivo General

Analizar la evolución temporal del crecimiento y las desigualdades de género en las matrículas y titulaciones de la educación superior en Bolivia, para identificar las áreas de estudio y ciudades con mayores brechas educativas.

1.3.2. Objetivos Específicos

- **Cuantificar la evolución de la matrícula:** Identificar las tasas de crecimiento anual de inscritos en el sistema universitario boliviano durante el periodo de estudio.
- **Identificar brechas de género:** Comparar la distribución de hombres y mujeres en las distintas áreas del conocimiento y niveles de titulación.
- **Analizar la concentración geográfica:** Determinar qué departamentos o ciudades concentran la mayor oferta y demanda académica, contrastándola con las zonas de menor acceso.
- **Evaluar la relación entre oferta y formalidad:** Explorar descriptivamente si las áreas de estudio con mayor crecimiento coinciden con los sectores económicos de mayor informalidad en el país.
- **Proyectar tendencias futuras:** Aplicar modelos descriptivos para estimar el comportamiento de la matrícula en los próximos años basándose en los datos históricos.

1.4. Justificación y alcance

Lorem ipsum dolor sit amet, consectetuer adipiscing elit.

1.5. Metodología usada

Para el análisis de los datos se usará lo que es la metodologia CRISP-DM que es un acrónimo de de Cross-Industry Standard Process for Data Mining. Este es un modelo de proceso estándar, ampliamente reconocido y utilizado en la industria, que describe los pasos necesarios para llevar a cabo con éxito un proyecto de minería de datos o de análisis de datos. Este marco de trabajo proporciona una estructura iterativa y cíclica que organiza el flujo de trabajo en las siguientes seis fases:

1. **Comprensión del Negocio (Business Understanding)**: Esta fase inicial se centra en la definición de los objetivos del proyecto y los requisitos desde una perspectiva de negocio o la institución.
2. **Comprensión de los Datos (Data Understanding)**: Consiste en la recolección inicial de datos y la realización de actividades destinadas a familiarizarse con ellos.
3. **Preparación de los Datos (Data Preparation)**: Esta etapa abarca todas las actividades necesarias para construir el conjunto de datos final que será introducido en las herramientas de modelado.
4. **Modelado (Modeling)**: En esta fase se seleccionan y aplican diversas técnicas de modelado y se calibran sus parámetros a valores óptimos. Debido a que algunas técnicas requieren formatos de datos específicos, a menudo es necesario regresar a la fase de preparación de datos durante este proceso.
5. **Evaluación (Evaluation)**: Una vez construido el modelo (o modelos), se debe evaluar su calidad, eficacia y si el modelo cumple con los objetivos definidos en la primera fase y se determina si existe alguna razón importante por la cual el modelo no deba ser utilizado.
6. **Despliegue (Deployment)**: Los conocimientos obtenidos deben ser organizados y presentados de manera que el usuario final pueda utilizarlos.

La metodología CRISP-DM destaca por su naturaleza cíclica y su versatilidad, siendo un estándar agnóstico al sector o tecnología empleada. Su valor reside en su capacidad para alinear los requisitos técnicos con las metas estratégicas del negocio. La elección de este marco responde a su robustez y rigor, garantizando que el proceso siga un hilo conductor sistemático —desde la fase de observación hasta la evaluación final— sin omitir etapas fundamentales del método científico. Entre sus ventajas adicionales se encuentran:

- Replicabilidad y documentación
- Naturaleza iterativa y no lineal
- Mitigación de sesgos y error temprano (énfasis en la fase de comprensión de los datos)
- Alineación con el estado del arte (evaluación)

1.6. Caracterización y exploración del corpus de datos

1.6.1. Identificación de la fuente de información

Lorem ipsum dolor sit amet, consectetuer adipiscing elit.

1.6.2. Diccionario de Variables y Atributos

El conjunto de datos utilizado para esta investigación contiene registros históricos sobre el sistema universitario boliviano. A continuación, se presenta el diccionario de datos que describe las variables analizadas:

- **ÁREA:** Categoría general del conocimiento a la que pertenece la carrera (ej. Ciencias de la Salud, Ciencias Económicas).
- **CARRERA:** Nombre específico del programa académico.
- **CIUDAD:** Ubicación geográfica (Departamento) donde se encuentra la sede universitaria.
- **AÑO:** Período de registro de los datos (variable temporal).
- **TIPO DE EDUCACIÓN:** Clasificación de la institución según su dependencia (Pública o Privada).
- **MATRICULADOS (H/M):** Número total de alumnos inscritos en la gestión, desglosado por hombres (H) y mujeres (M).

- **NUEVOS (H/M):** Cantidad de alumnos que ingresaron por primera vez a la carrera en ese año (estudiantes nuevos).

- **TITULADOS (H/M):** Cantidad de estudiantes que completaron sus estudios y obtuvieron su grado académico en esa gestión.

1.6.3. Análisis exploratorio de datos (EDA)

Los datos son de naturaleza diversa. Se verán algunas de las columnas numéricas representadas gráficamente. Se puede ver como muchos de los datos están desbalanceados de manera considerable, dejando a muchos datos fuera de los cuartiles 1 y 3, esto en la 1. Respecto a como se escogen las carreras, se puede observar como existen diferencias entre hombres y mujeres. En la figura 2 se puede ver que existen carreras como las de Salud que tiene proporciones más altas de mujeres, o como Ingeniería que igual tiene diferencias pero no son tan marcadas.

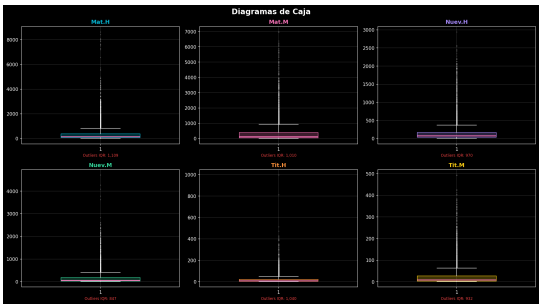

Figura 1: Boxplot de las columnas numéricas

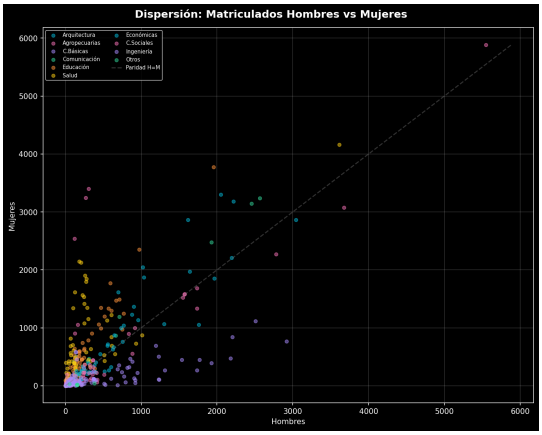

Figura 2: Gráfico de dispersión

Esta difernecia entre los géneros y carreras se puede ver con mayor claridad en el gráfico 3. Allí se puede ver como Salud efectivamente tiene la diferencia más marcada. Del mismo modo, las diferencias entre los departamentos se pueden ver en la figura 4.

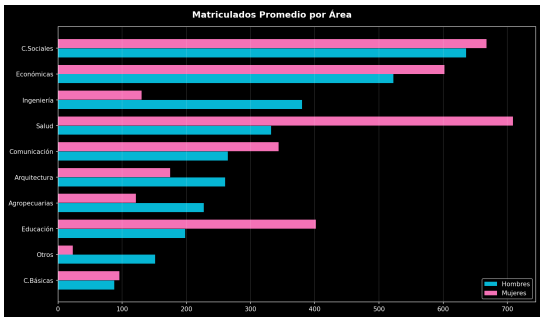

Figura 3: Gráfico de barras por área

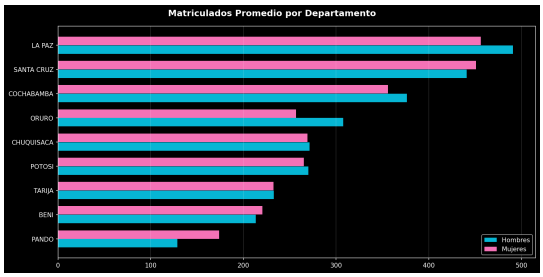

Figura 4: Gráfico de barras por ciudad

Como los datos tienen una columan para el tiempo, tambien podemos verlo en la 5 como una evolución temporal. Para ver como es que los datos están desbalanceados, se puede ver la 6. En este caso la diferencia entre la mediana y la media es grande.

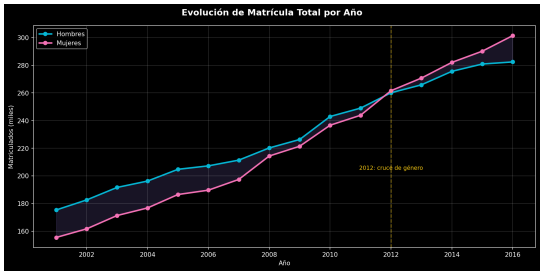

Figura 5: Gráfico de barras por ciudad

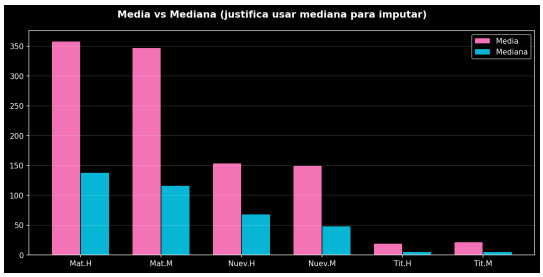

Figura 6: Gráfico de barras por ciudad

Finalmente la comparación entre universidades públicas y privadas se puede ver en la 7

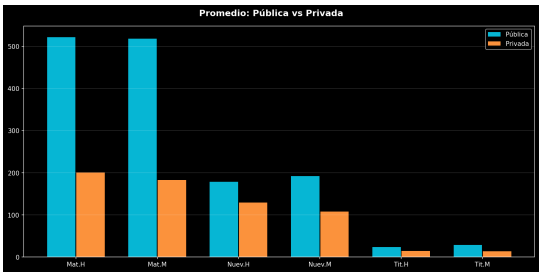

Figura 7: Gráfico de barras por ciudad

1.6.4. Análisis descriptivo y medidas de tendencia central

Se usaron scripts de python para sacar las medidas descriptivas.

Estadisticas 1:

```
========================================
MÉTRICAS DESCRIPTIVAS
========================================
   Var     N  Media  Mediana   Std  Mín
 Mat.H 10263  357.8    138.0 607.8  0.0
 Mat.M 10263  347.0    116.0 633.0  0.0
Nuev.H 10263  153.5     68.0 260.3  0.0
Nuev.M 10263  149.2     48.0 283.8  0.0
 Tit.H 10263   18.9      5.0  40.1  0.0
 Tit.M 10263   21.3      5.0  43.9  0.0

======================
MÉTRICAS DESCRIPTIVAS
======================
    Máx  Asimetría  Curtosis
 8628.0        4.7      35.5
 6978.0        4.1      23.1
 2944.0        4.1      22.0
 4712.0        4.9      36.7
  997.0        5.8      70.2
  494.0        4.0      21.2
```

Estadisticas 2:

```
=========================================
MÉTRICAS DESCRIPTIVAS
=========================================
                    Mat.H  Mat.M  Nuev.H
TIPO DE EDUCACIÓN
PRIVADA             200.7  183.1   129.6
PUBLICA             522.1  518.3   178.4

===================
MÉTRICAS DESCRIPTIVAS
===================
Nuev.M  Tit.H  Tit.M

 108.3   14.4   13.8
 191.9   23.5   29.1
```

Estadisticas 3:

```
==================================
MÉTRICAS DESCRIPTIVAS
==================================
            Hombres  Mujeres  Total
CIUDAD
LA PAZ        490.7    456.0  946.7
SANTA CRUZ    440.9    450.8  891.7
COCHABAMBA    376.5    356.1  732.6
ORURO         307.6    256.8  564.4
CHUQUISACA    271.4    269.2  540.6
POTOSI        270.0    265.1  535.1
TARIJA        233.0    232.6  465.6
BENI          213.3    220.4  433.7
PANDO         128.9    173.7  302.6
```

1.6.5. Diagnóstico de la calidad de los datos

Al inspeccionar la muestra de datos, se observa que existen registros con valores en cero en las columnas de matriculados y titulados (ej. Medicina en Beni en 2007). Esto sugiere la necesidad de un proceso de limpieza para distinguir entre carreras sin movimiento académico y posibles omisiones de registro en la fuente original.

1.6.6. Análisis e intepretacion preliminar de los datos

Primeras interpretaciones visuales y estadísticas.
Lorem ipsum dolor sit amet, consectetuer adipiscing elit.

2. Preparación de los datos

2.1. Imputación de datos faltantes

Para ver si existen datos faltantes se corrió un script que mostraba los mismos. El resultado fue este:

```
==========================================
2. DATOS FALTANTES
==========================================
  Filas sin datos (todos ceros): 2,301 (22.4%)

  Variable     Faltantes     Media   Mediana
  ------------ --------- --------- ---------
  Mat.H            2,301     417.3     176.0
  Mat.M            2,301     408.0     141.0
  Nuev.H           2,301     176.7      76.0
  Nuev.M           2,301     175.1      64.0
  Tit.H            2,301      21.3       6.0
  Tit.M            2,301      25.2       6.0

========================
2. DATOS FALTANTES
========================
301 (22.4%)

  Mediana
---------
    176.0
    141.0
     76.0
```

```
    64.0
     6.0
     6.0

Método: mediana por grupo (ÁREA + TIPO DE EDUCACIÓN)
NaN restantes: 0
```

Los datos fueron imputados con la mediana debido a que esta no incurre en un sesgo mayor como el que produce la media, que en este caso al ser una distribución sesgada podria producir un desbalance mayor.

2.2. Tratamiento de outliers

Para detectar los outliers se utilizó dos métodos. El primero es el IQR en los cuartiles 1 y 3, con ello se puedo ver los siguiente:

```
====================================
3. DETECCIÓN DE OUTLIERS
====================================

 Método IQR (1.5 × IQR)
Var            Q1      Q3     IQR
Mat.H          65     374     308
Mat.M          37     395     358
Nuev.H         36     170     134
Nuev.M         22     179     157
Tit.H           3      22      19
Tit.M           3      27      24

========================
3. DETECCIÓN DE OUTLIERS
========================

Límite Outliers      %
   836    1,109  11.1%
   932    1,010  10.1%
   371      970  10.1%
   414      847   8.9%
    50    1,040  12.6%
    63      932  11.7%
```

También se usó la Winsorización al 5 y 95 %

```
 Winsorización (P5 { P95)
Var          Media    → Win
Mat.H        366.7    322.4
Mat.M        357.8    304.8
Nuev.H       164.2    140.2
Nuev.M       160.6    133.5
Tit.H         23.4     20.3
Tit.M         27.3     23.7

 Winsorización (P5 { P95)
    Std    → Win   Afect
  612.6    407.0     991
  639.8    409.4     961
  266.0    161.0     952
  291.4    168.5     839
   43.5     29.0     411
   48.1     33.2     400
```

Finalmente antes de realizar una acción se comparó ambos resultados:

```
 Comparativa
Var            IQR   Winsor
Mat.H        1,109      991
Mat.M        1,010      961
Nuev.H         970      952
Nuev.M         847      839
Tit.H        1,040      411
Tit.M          932      400
→ IQR es más estricto en todas las variables.
```

Se escogió el segundo método ya que tenia muchos menos outliers y además los preservaba en vez de eliminarlos. Se puede ver un resultado gráfico en la 8

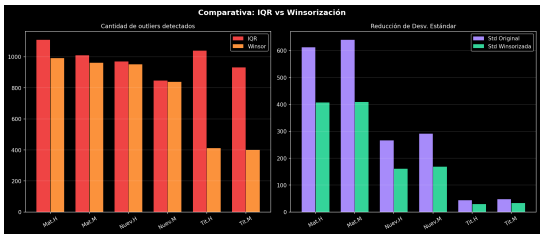

Figura 8: Gráfico de barras por ciudad